

## 矩阵求导术（上）



长驱鬼侠  
数学爱好者

关注他

1,680 人赞了该文章

矩阵求导的技术，在统计学、控制论、机器学习等领域有广泛的应用。鉴于我看过的一些资料或言之不详、或繁乱无绪，本文来做科普，分作两篇，上篇讲标量对矩阵的求导术，下篇讲矩阵对矩阵的求导术。本文使用小写字母 $x$ 表示标量，粗体小写字母 $\mathbf{x}$ 表示（列）向量，大写字母 $X$ 表示矩阵。

首先来琢磨一下定义，标量 $f$ 对矩阵 $X$ 的导数，定义为 $\frac{\partial f}{\partial X} = \left[ \frac{\partial f}{\partial X_{ij}} \right]$ ，即 $f$ 对 $X$ 逐元素求导排成与 $X$ 尺寸相同的矩阵。然而，这个定义在计算中并不好用，实用上的原因是对函数较复杂的情形难以逐元素求导；哲学上的原因是逐元素求导破坏了整体性。试想，为何要将 $f$ 看做矩阵 $X$ 而不是各元素 $X_{ij}$ 的函数呢？答案是用矩阵运算更整洁。所以在求导时不宜拆开矩阵，而是要找一个从整体出发的算法。

为此，我们来回顾，一元微积分中的导数（标量对标量的导数）与微分有联系： $df = f'(x)dx$ ；多元微积分中的梯度（标量对向量的导数）也与微分有联系：

$$df = \sum_{i=1}^n \frac{\partial f}{\partial x_i} dx_i = \frac{\partial f^T}{\partial \mathbf{x}} d\mathbf{x}, \text{ 这里第一个等号是全微分公式，第二个等号表达了梯度与微}$$

分的联系：全微分 $df$ 是梯度向量 $\frac{\partial f}{\partial \mathbf{x}}$ （ $n \times 1$ ）与微分向量 $d\mathbf{x}$ （ $n \times 1$ ）的内积；受此启发，我们将矩

$$\text{阵导数与微分建立联系：} df = \sum_{i=1}^m \sum_{j=1}^n \frac{\partial f}{\partial X_{ij}} dX_{ij} = \text{tr} \left( \frac{\partial f^T}{\partial X} dX \right). \text{ 其中tr代表迹}$$

(trace)是方阵对角线元素之和，满足性质：对尺寸相同的矩阵 $A, B$ ， $\text{tr}(A^T B) = \sum_{i,j} A_{ij} B_{ij}$

，即 $\text{tr}(A^T B)$ 是矩阵 $A, B$ 的内积。与梯度相似，这里第一个等号是全微分公式，第二个等号表达

了矩阵导数与微分的联系：全微分 $df$ 是导数 $\frac{\partial f}{\partial X}$ （ $m \times n$ ）与微分矩阵 $dX$ （ $m \times n$ ）的内积。

然后来建立运算法则。回想遇到较复杂的一元函数如 $f = \log(2 + \sin x)e^{\sqrt{x}}$ ，我们是如何求导的呢？通常不是从定义开始求极限，而是先建立了初等函数求导和四则运算、复合等法则，再来运用这些法则。故而，我们来创立常用的矩阵微分的运算法则：

1. 加减法： $d(X \pm Y) = dX \pm dY$ ；矩阵乘法： $d(XY) = (dX)Y + XdY$ ；转置： $d(X^T) = (dX)^T$ ；迹： $d\text{tr}(X) = \text{tr}(dX)$ 。
2. 逆： $dX^{-1} = -X^{-1}dXX^{-1}$ 。此式可在 $XX^{-1} = I$ 两侧求微分来证明。
3. 行列式： $d|X| = \text{tr}(X^\# dX)$ ，其中 $X^\#$ 表示 $X$ 的伴随矩阵，在 $X$ 可逆时又可以写作 $d|X| = |X|\text{tr}(X^{-1}dX)$ 。此式可用Laplace展开来证明，详见张贤达《矩阵分析与应用》第279页。
4. 逐元素乘法： $d(X \odot Y) = dX \odot Y + X \odot dY$ ， $\odot$ 表示尺寸相同的矩阵 $X, Y$ 逐元素相乘。
5. 逐元素函数： $d\sigma(X) = \sigma'(X) \odot dX$ ， $\sigma(X) = [\sigma(X_{ij})]$ 是逐元素标量函数运算， $\sigma'(X) = [\sigma'(X_{ij})]$ 是逐元素求导数。举个例子，

赞同 1.7K

176 条评论

分享

收藏



$$X = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \end{bmatrix}, d\sin(X) = \begin{bmatrix} \cos x_{11} dx_{11} & \cos x_{12} dx_{12} \\ \cos x_{21} dx_{21} & \cos x_{22} dx_{22} \end{bmatrix} = \cos(X) \odot dX$$

。

我们试图利用矩阵导数与微分的联系  $df = \text{tr} \left( \frac{\partial f^T}{\partial X} dX \right)$ ，在求出左侧的微分  $df$  后，该如何写成右侧的形式并得到导数呢？这需要一些迹技巧(trace trick)：

1. 标量套上迹： $a = \text{tr}(a)$
2. 转置： $\text{tr}(A^T) = \text{tr}(A)$ 。
3. 线性： $\text{tr}(A \pm B) = \text{tr}(A) \pm \text{tr}(B)$ 。
4. 矩阵乘法交换： $\text{tr}(AB) = \text{tr}(BA)$ ，其中  $A$  与  $B^T$  尺寸相同。两侧都等于  $\sum_{i,j} A_{ij} B_{ji}$ 。
5. 矩阵乘法/逐元素乘法交换： $\text{tr}(A^T(B \odot C)) = \text{tr}((A \odot B)^T C)$ ，其中  $A, B, C$  尺寸相同。两侧都等于  $\sum_{i,j} A_{ij} B_{ij} C_{ij}$ 。

观察一下可以断言，若标量函数  $f$  是矩阵  $X$  经加减乘法、逆、行列式、逐元素函数等运算构成，则使用相应的运算法则对  $f$  求微分，再使用迹技巧给  $df$  套上迹并将其它项交换至  $dX$  左侧，即能得到导数。

在建立法则的最后，来谈一谈复合：假设已求得  $\frac{\partial f}{\partial Y}$ ，而  $Y$  是  $X$  的函数，如何求  $\frac{\partial f}{\partial X}$  呢？在微积分中有标量求导的链式法则  $\frac{\partial f}{\partial x} = \frac{\partial f}{\partial y} \frac{\partial y}{\partial x}$ ，但这里我们不能沿用链式法则，因为矩阵对矩阵的导数  $\frac{\partial Y}{\partial X}$  截至目前仍是未定义的。于是我们继续追本溯源，链式法则是从何而来？源头仍然是微分。我们直接从微分入手建立复合法则：先写出  $df = \text{tr} \left( \frac{\partial f^T}{\partial Y} dY \right)$ ，再将  $dY$  用  $dX$  表示出来代入，并使用迹技巧将其他项交换至  $dX$  左侧，即可得到  $\frac{\partial f}{\partial X}$ 。

接下来演示一些算例。特别提醒要依据已经建立的运算法则来计算，不能随意套用微积分中标量导数的结论，比如认为  $AX$  对  $X$  的导数为  $A$ ，这是没有根据、意义不明的。

例1： $f = a^T X b$ ，求  $\frac{\partial f}{\partial X}$ 。其中  $a$  是  $m \times 1$  列向量， $X$  是  $m \times n$  矩阵， $b$  是  $n \times 1$  列向量， $f$  是标量。

解：先使用矩阵乘法法则求微分，这里的  $a, b$  是常量， $da = 0, db = 0$ ，得到：

$df = a^T dX b$ ，再套上迹并做矩阵乘法交换： $df = \text{tr}(a^T dX b) = \text{tr}(b a^T dX)$ ，注意这里我们根据  $\text{tr}(AB) = \text{tr}(BA)$  交换了  $a^T dX$  与  $b$ 。对照导数与微分的联系

$$df = \text{tr} \left( \frac{\partial f^T}{\partial X} dX \right)，得到 \frac{\partial f}{\partial X} = (b a^T)^T = a b^T。$$

注意：这里不能用  $\frac{\partial f}{\partial X} = a^T \frac{\partial X}{\partial X} b = ?$ ，导数与乘常数矩阵的交换是不合法则的运算（而微分是合法的）。有些资料在计算矩阵导数时，会略过求微分这一步，这是逻辑上解释不通的。

例2:  $f = \mathbf{a}^T \exp(X\mathbf{b})$ , 求  $\frac{\partial f}{\partial X}$ 。其中  $\mathbf{a}$  是  $m \times 1$  列向量,  $X$  是  $m \times n$  矩阵,  $\mathbf{b}$  是  $n \times 1$  列向量,  $\exp$  表示逐元素求指数,  $f$  是标量。

解: 先使用矩阵乘法、逐元素函数法则求微分:  $df = \mathbf{a}^T (\exp(X\mathbf{b}) \odot (dX\mathbf{b}))$ , 再套上迹并做

$df = \text{tr}(\mathbf{a}^T (\exp(X\mathbf{b}) \odot (dX\mathbf{b}))) = \text{tr}((\mathbf{a} \odot \exp(X\mathbf{b}))^T dX\mathbf{b}) = \text{tr}(\mathbf{b}(\mathbf{a} \odot \exp(X\mathbf{b}))^T dX)$ , 注意这里我们先根据  $\text{tr}(A^T(B \odot C)) = \text{tr}((A \odot B)^T C)$  交换了  $\mathbf{a}$ 、 $\exp(X\mathbf{b})$  与  $dX\mathbf{b}$ , 再根据  $\text{tr}(AB) = \text{tr}(BA)$  交换了  $(\mathbf{a} \odot \exp(X\mathbf{b}))^T dX$  与  $\mathbf{b}$ 。对照导数与微分的

联系  $df = \text{tr} \left( \frac{\partial f}{\partial X}^T dX \right)$ , 得到

$$\frac{\partial f}{\partial X} = (\mathbf{b}(\mathbf{a} \odot \exp(X\mathbf{b}))^T)^T = (\mathbf{a} \odot \exp(X\mathbf{b}))\mathbf{b}^T。$$

例3:  $f = \text{tr}(Y^T M Y)$ ,  $Y = \sigma(WX)$ , 求  $\frac{\partial f}{\partial X}$ 。其中  $W$  是  $l \times m$  列向量,  $X$  是  $m \times n$  矩阵,  $Y$  是  $l \times n$  矩阵,  $M$  是  $l \times l$  对称矩阵,  $\sigma$  是逐元素函数,  $f$  是标量。

解: 先求  $\frac{\partial f}{\partial Y}$ , 求微分, 使用矩阵乘法、转置法则:

$df = \text{tr}((dY)^T M Y) + \text{tr}(Y^T M dY) = 2\text{tr}(Y^T M dY)$ , 对照导数与微分的联系, 得

到  $\frac{\partial f}{\partial Y} = 2MY$ 。为求  $\frac{\partial f}{\partial X}$ , 写出  $df = \text{tr} \left( \frac{\partial f}{\partial Y}^T dY \right)$ , 再将  $dY$  用  $dX$  表示出来代入, 并

使用矩阵乘法/逐元素乘法交换:

$$df = \text{tr} \left( \frac{\partial f}{\partial Y}^T (\sigma'(WX) \odot (W dX)) \right) = \text{tr} \left( \left( \frac{\partial f}{\partial Y} \odot \sigma'(WX) \right)^T W dX \right), \text{对}$$

照导数与微分的联系, 得到

$$\frac{\partial f}{\partial X} = W^T \left( \frac{\partial f}{\partial Y} \odot \sigma'(WX) \right) = W^T ((2M\sigma(WX)) \odot \sigma'(WX))。$$

例4【线性回归】:  $l = \|X\mathbf{w} - \mathbf{y}\|^2$ , 求  $\mathbf{w}$  的最小二乘估计, 即求  $\frac{\partial l}{\partial \mathbf{w}}$  的零点。其中  $\mathbf{y}$  是  $m \times 1$  列向量,  $X$  是  $m \times n$  矩阵,  $\mathbf{w}$  是  $n \times 1$  列向量,  $l$  是标量。

解: 严格来说这是标量对向量的导数, 不过可以把向量看做矩阵的特例。先将向量模平方改写成向量与自身的内积:  $l = (X\mathbf{w} - \mathbf{y})^T (X\mathbf{w} - \mathbf{y})$ , 求微分, 使用矩阵乘法、转置等法则:

$dl = (X d\mathbf{w})^T (X\mathbf{w} - \mathbf{y}) + (X\mathbf{w} - \mathbf{y})^T (X d\mathbf{w}) = 2(X\mathbf{w} - \mathbf{y})^T X d\mathbf{w}$ 。对照导数与

微分的联系  $dl = \frac{\partial l}{\partial \mathbf{w}}^T d\mathbf{w}$ , 得到  $\frac{\partial l}{\partial \mathbf{w}} = (2(X\mathbf{w} - \mathbf{y})^T X)^T = 2X^T (X\mathbf{w} - \mathbf{y})$ 。

$\frac{\partial l}{\partial \mathbf{w}}$  的零点即  $\mathbf{w}$  的最小二乘估计为  $\mathbf{w} = (X^T X)^{-1} X^T \mathbf{y}$ 。

例5【方差的最大似然估计】: 样本  $\mathbf{x}_1, \dots, \mathbf{x}_n \sim N(\boldsymbol{\mu}, \Sigma)$ , 求方差  $\Sigma$  的最大似然估计。写成数学式是:  $l = \log |\Sigma| + \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})^T \Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$ , 求  $\frac{\partial l}{\partial \Sigma}$  的零点。其中  $\mathbf{x}_i$  是

$m \times 1$  列向量,  $\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$  是样本均值,  $\Sigma$  是  $m \times m$  对称正定矩阵,  $l$  是标量。

解: 首先求微分, 使用矩阵乘法、行列式、逆等运算法则, 第一项是

$d \log |\Sigma| = |\Sigma|^{-1} d|\Sigma| = \text{tr}(\Sigma^{-1} d\Sigma)$ , 第二项是

$$\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})^T d\Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) = -\frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})$$

赞同 1.7K

176 条评论

分享

收藏

第二项套上述做交换： $\text{tr} \left( \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}})^T \Sigma^{-1} d\Sigma \Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) \right)$

$$= \frac{1}{n} \sum_{i=1}^n \text{tr}((\mathbf{x}_i - \bar{\mathbf{x}})^T \Sigma^{-1} d\Sigma \Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}))$$

$$= \frac{1}{n} \sum_{i=1}^n \text{tr}(\Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T \Sigma^{-1} d\Sigma) = \text{tr}(\Sigma^{-1} S \Sigma^{-1} d\Sigma)$$

，其中先交换迹与求和，然后将  $\Sigma^{-1} (\mathbf{x}_i - \bar{\mathbf{x}})$  交换到左边，最后再交换迹与求和，并定义

$$S = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^T$$

为样本方差矩阵。得到

$$dl = \text{tr}((\Sigma^{-1} - \Sigma^{-1} S \Sigma^{-1}) d\Sigma)$$

。对照导数与微分的联系，有

$$\frac{\partial l}{\partial \Sigma} = (\Sigma^{-1} - \Sigma^{-1} S \Sigma^{-1})^T$$

，其零点即  $\Sigma$  的最大似然估计为  $\Sigma = S$ 。

例6【多元logistic回归】： $l = -\mathbf{y}^T \log \text{softmax}(W\mathbf{x})$ ，求  $\frac{\partial l}{\partial W}$ 。其中  $\mathbf{y}$  是除一个元素为1外其它元素为0的  $m \times 1$  列向量， $W$  是  $m \times n$  矩阵， $\mathbf{x}$  是  $n \times 1$  列向量， $l$  是标量；

$$\text{softmax}(\mathbf{a}) = \frac{\exp(\mathbf{a})}{\mathbf{1}^T \exp(\mathbf{a})}$$

，其中  $\exp(\mathbf{a})$  表示逐元素求指数， $\mathbf{1}$  代表全1向量。

解：首先将softmax函数代入并写成

$$l = -\mathbf{y}^T (\log(\exp(W\mathbf{x})) - \mathbf{1} \log(\mathbf{1}^T \exp(W\mathbf{x}))) = -\mathbf{y}^T W\mathbf{x} + \log(\mathbf{1}^T \exp(W\mathbf{x}))$$

，这里要注意逐元素log满足等式  $\log(\mathbf{u}/c) = \log(\mathbf{u}) - \mathbf{1} \log(c)$ ，以及  $\mathbf{y}$  满足  $\mathbf{y}^T \mathbf{1} = 1$ 。

求微分，使用矩阵乘法、逐元素函数等法则：

$$dl = -\mathbf{y}^T dW\mathbf{x} + \frac{\mathbf{1}^T (\exp(W\mathbf{x}) \odot (dW\mathbf{x}))}{\mathbf{1}^T \exp(W\mathbf{x})}$$

。再套上述并做交换，注意可化简

$$\mathbf{1}^T (\exp(W\mathbf{x}) \odot (dW\mathbf{x})) = \exp(W\mathbf{x})^T dW\mathbf{x}$$

，这是根据等式  $\mathbf{1}^T (\mathbf{u} \odot \mathbf{v}) = \mathbf{u}^T \mathbf{v}$ ，

$$\text{故 } dl = \text{tr} \left( -\mathbf{y}^T dW\mathbf{x} + \frac{\exp(W\mathbf{x})^T dW\mathbf{x}}{\mathbf{1}^T \exp(W\mathbf{x})} \right) = \text{tr}(\mathbf{x}(\text{softmax}(W\mathbf{x}) - \mathbf{y})^T dW)$$

。对照导数与微分的联系，得到  $\frac{\partial l}{\partial W} = (\text{softmax}(W\mathbf{x}) - \mathbf{y})\mathbf{x}^T$ 。

另解：定义  $\mathbf{a} = W\mathbf{x}$ ，则  $l = -\mathbf{y}^T \log \text{softmax}(\mathbf{a})$ ，先如上求出

$$\frac{\partial l}{\partial \mathbf{a}} = \text{softmax}(\mathbf{a}) - \mathbf{y}$$

，再利用复合法则：

$$dl = \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}}^T d\mathbf{a} \right) = \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}}^T dW\mathbf{x} \right) = \text{tr} \left( \mathbf{x} \frac{\partial l}{\partial \mathbf{a}}^T dW \right)$$

，得到

$$\frac{\partial l}{\partial W} = \frac{\partial l}{\partial \mathbf{a}} \mathbf{x}^T$$

最后一例留给经典的神经网络。神经网络的求导术是学术史上的重要成果，还有个专门的名字叫做BP算法，我相信如今很多人在初次推导BP算法时也会颇费一番脑筋，事实上使用矩阵求导术来推导并不复杂。为简化起见，我们推导二层神经网络的BP算法。

例7【二层神经网络】： $l = -\mathbf{y}^T \log \text{softmax}(W_2 \sigma(W_1 \mathbf{x}))$ ，求  $\frac{\partial l}{\partial W_1}$  和  $\frac{\partial l}{\partial W_2}$ 。其中  $\mathbf{y}$  是除一个元素为1外其它元素为0的  $m \times 1$  列向量， $W_2$  是  $m \times p$  矩阵， $W_1$  是  $p \times n$  矩阵， $\mathbf{x}$  是  $n \times 1$  列向量， $l$  是标量； $\text{softmax}(\mathbf{a}) = \frac{\exp(\mathbf{a})}{\mathbf{1}^T \exp(\mathbf{a})}$  同例3， $\sigma(\cdot)$  是逐元素

$$\text{sigmoid函数 } \sigma(a) = \frac{1}{1 + \exp(-a)}$$

解：定义  $\mathbf{a}_1 = W_1 \mathbf{x}$  ,  $\mathbf{h}_1 = \sigma(\mathbf{a}_1)$  ,  $\mathbf{a}_2 = W_2 \mathbf{h}_1$  , 则  $l = -\mathbf{y}^T \log \text{softmax}(\mathbf{a}_2)$ 。

在前例中已求出  $\frac{\partial l}{\partial \mathbf{a}_2} = \text{softmax}(\mathbf{a}_2) - \mathbf{y}$ 。使用复合法则，注意此处  $\mathbf{h}_1, W_2$  都是变量：

$$d\mathbf{l} = \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}_2}^T d\mathbf{a}_2 \right) = \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}_2}^T dW_2 \mathbf{h}_1 \right) + \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}_2}^T W_2 d\mathbf{h}_1 \right), \text{使用矩阵乘}$$

法交换的迹技巧从第一项得到  $\frac{\partial l}{\partial W_2} = \frac{\partial l}{\partial \mathbf{a}_2} \mathbf{h}_1^T$  , 从第二项得到  $\frac{\partial l}{\partial \mathbf{h}_1} = W_2^T \frac{\partial l}{\partial \mathbf{a}_2}$ 。接下来

求  $\frac{\partial l}{\partial \mathbf{a}_1}$  , 继续使用复合法则，并利用矩阵乘法和逐元素乘法交换的迹技巧：

$$\text{tr} \left( \frac{\partial l}{\partial \mathbf{h}_1}^T d\mathbf{h}_1 \right) = \text{tr} \left( \frac{\partial l}{\partial \mathbf{h}_1}^T (\sigma'(\mathbf{a}_1) \odot d\mathbf{a}_1) \right) = \text{tr} \left( \left( \frac{\partial l}{\partial \mathbf{h}_1} \odot \sigma'(\mathbf{a}_1) \right)^T d\mathbf{a}_1 \right)$$

, 得到  $\frac{\partial l}{\partial \mathbf{a}_1} = \frac{\partial l}{\partial \mathbf{h}_1} \odot \sigma'(\mathbf{a}_1)$ 。为求  $\frac{\partial l}{\partial W_1}$  , 再用一次复合法则：

$$\text{tr} \left( \frac{\partial l}{\partial \mathbf{a}_1}^T d\mathbf{a}_1 \right) = \text{tr} \left( \frac{\partial l}{\partial \mathbf{a}_1}^T dW_1 \mathbf{x} \right) = \text{tr} \left( \mathbf{x} \frac{\partial l}{\partial \mathbf{a}_1}^T dW_1 \right), \text{得到}$$

$$\frac{\partial l}{\partial W_1} = \frac{\partial l}{\partial \mathbf{a}_1} \mathbf{x}^T.$$

下篇见 [zhuanlan.zhihu.com/p/24...](https://zhuanlan.zhihu.com/p/24...)。

编辑于 2018-11-09

机器学习 矩阵分析 优化

## 推荐阅读

### 矩阵求导浅析（一）

本文主要关注标量函数对矩阵的求导，并提供一种简明直观易操作的矩阵求导方法。推荐矩阵求导相关的专栏文章：矩阵求导术（上）矩阵求导术（下）机器学习中的矩阵/向量求导1.内积 向量

倚楼

### 机器学习中的矩阵/向量求导

“矩阵求导”似乎是一个三不管的区域。虽然原理确实是数学分析中所讲的多元函数求导，但是总结一些公式以及复合函数求导的法则还是必要的，毕竟逐分量地求导太累而且易出错，例如一旦涉及矩...

Towser



机器学习

章华燕

176 条评论

⇌ 切换为时间排序

写下你的评论...



### 精选评论（2）



resurrectcore

1 年前

网上有个pdf叫做 The Matrix Cookbook.

👍 19    💬 查看回复



Liwei Cai 回复 resurrectcore

1 年前

我看过，相信写这篇文章的人也看过。感觉这里的方法比硬背公式简单，而且对于搞机器学习的这里的够用了

👍 11    💬 查看回复

▲ 赞同 1.7K ▼

💬 176 条评论

➦ 分享

★ 收藏